CENTRO PAULA SOUZA
FACULDADE DE TECNOLOGIA DE FRANCA
"Dr. THOMAZ NOVELINO"

TECNOLOGIA EM DESENVOLVIMENTO DE SOFTWARE MULTIPLATAFORMA

GUILHERME LUÍS RODRIGUES SILVA
MIGUEL ANGELO SILVA

RELATÓRIO DO FLUXO DE MINERAÇÃO DE DADOS

CLASSIFICAÇÃO DE ESTUDANTES EM RISCO DE EVASÃO COM APRENDIZADO SUPERVISIONADO

FRANCA/SP

2026

1. RESUMO

Este relatório apresenta o andamento do fluxo de mineração de dados do projeto. O objetivo é classificar a situação acadêmica de um estudante em três categorias (evasão, matrícula ativa ou conclusão do curso) a partir de 36 atributos demográficos, socioeconômicos e de desempenho. O resultado serve de apoio para que a instituição identifique e priorize os estudantes que precisam de acompanhamento.

ITEM	VALOR
Instâncias	4.424
Atributos de entrada	36
Classes	3
Instâncias de treinamento e validação	3.539(80%)
Instâncias de teste	885(20%)
Algoritmo comparados	13
Modelo Escolhido	Regressão logística
Acurácia no teste	76,84%
Acurácia balanceada no teste	67,54%
Revocação da evasão no teste	76,76%

2. ANDAMENTO DO PROJETO

Seguem em aberto duas frentes complementares: a integração do processamento em lote via Kafka, já implementada e em fase de versionamento, e a codificação one-hot dos atributos categóricos, prevista como melhoria do modelo.

ETAPA	DESCRIÇÃO	SITUAÇÃO
Entendimento do problema	Definição da tarefa como classificação em três classes	Concluída
Entendimento dos dados	Análise de tipos, valores ausentes, duplicados e distribuição das classes	Concluída
Preparação	Verificação e limpeza da base	Concluída

Transformação	Codificação do alvo e padronização dos atributos	Concluída
Seleção de atributos	Definição dos 36 atributos usados pelo modelo e pela API	Concluída
Treinamento	Comparação de 13 algoritmos por validação cruzada	Concluída
Avaliação	Teste final em dados não vistos no treino	Concluída
Interpretação	Análise dos atributos mais influentes e das limitações	Concluída
Disponibilização	Modelo publicado via API e integrado à Web e ao Mobile	Concluída

3. BASE DE DADOS

Utilizamos a base Predict Students' Dropout and Academic Success, disponibilizada pelo UCI Machine Learning Repository. Ela reúne 4.424 estudantes de uma instituição de ensino superior portuguesa, descritos por 36 atributos e pela coluna-alvo Target. A base não tem valores ausentes nem registros duplicados e não identifica os estudantes.

CLASSE	**CONTEXTO**	**ESTUDANTES**	**PROPORÇÃO**
Dropout	Evasão	1.421	32,1%
Enrolled	Ainda Matriculado	794	18,0%
Graduate	Formado	2.209	49,9%
TOTAL		4.424	100%

A distribuição é desbalanceada: a classe Graduate tem 2,78 vezes mais registros que a Enrolled. Nesse cenário a acurácia isolada engana, já que um modelo que classificasse todos os estudantes como formados acertaria metade dos casos. Por isso também reportamos a acurácia balanceada, que dá o mesmo peso a cada classe.

Os atributos se dividem em 19 numéricos, 9 categóricos e 8 binários, organizados nos sete grupos da Tabela 4.

GRUPO	QUANTIDADE	EXEMPLOS
Perfil do estudante	7	Estado Civil, Nacionalidade, Gênero (Código do dataset).
Ingresso e Formação Anterior	7	Modalidade de ingresso, Ordem de opção do curso, Curso.
Contexto Familiar	4	Escolaridade da mãe, Escolaridade do pai, Ocupação da mãe.
Situação Financeira	3	Inadimplente, Mensalidades em dia, Bolsista.
Desempenho no 1°Semestre	6	UCs 1°Sem. aproveitadas, UCs 1°Sem. matriculadas, UCs 1°Sem. Avaliadas.
Desempenho no 2°Semestre	6	UCs 2°Sem. aproveitadas, UCs 2°Sem. matriculadas, UCs 2°Sem. Avaliadas.
Indicadores Econômicos	3	Taxa de desemprego, Taxa de inflação, PIB
Total	36	

4. PREPARAÇÃO E DIVISÃO DOS DADOS

A base não exigiu correções. A variável-alvo foi codificada como Dropout = 0, Enrolled = 1 e Graduate = 2, e os atributos foram padronizados com StandardScaler. O padronizador é ajustado apenas com os dados de treino, para que nenhuma informação do teste influencie o modelo.

Em seguida, os dados foram divididos em 80% para desenvolvimento e 20% para teste, de forma estratificada e com semente fixa (random_state = 42). Assim, a proporção das classes se mantém nos dois conjuntos e o resultado pode ser reproduzido.

CLASSE	DESENVOLVIMENTO	TESTE	TOTAL
Dropout	1.137	284	1.421
Enrolled	635	159	794

Graduate	1.767	442	2.209
TOTAL	3.539	885	4.424

O conjunto de teste ficou reservado para a avaliação final e não participou da escolha do modelo. A comparação entre algoritmos foi feita por validação cruzada estratificada de 10 folds dentro do conjunto de desenvolvimento, com cerca de 3.185 registros de treino e 354 de validação em cada rodada.

5. ESCOLHA DO MODELO

Comparamos 13 algoritmos de classificação. Para evitar uma escolha enviesada, o critério foi definido antes do treinamento e aplicado sobre as médias da validação cruzada, em três passos:

1. Descartamos os candidatos com diferença superior a 5 p.p. entre a acurácia de treino e a de validação, por indicarem sobreajuste.
2. Entre os restantes, calculamos a pontuação 0,5 × F1 macro + 0,5 × revocação da evasão. A revocação da evasão tem peso próprio porque, neste problema, deixar de identificar um estudante que vai evadir é o erro mais custoso.
3. Candidatos a menos de 0,01 da melhor pontuação foram considerados empatados, e o desempate favoreceu o mais estável.

ALGORITMO	PONTUAÇÃO	F1 MACRO	REV. EVASÃO	ACURÁCIA	DIFERENÇA TREINAMENTO VÁLIDO	SITUAÇÃO
Floresta aleatória (balanceada)	0,7344	0,7105	75,8%	77,8%	20,65 p.p.	Descartado
Gradient boosting	0,7316	0,6979	76,5%	77,4%	7,27 p.p.	Descartado
Floresta aleatória	0,7244	0,6869	76,2%	77,4%	19,56 p.p.	Descartado
Regressão logística	0,7205	0,6774	76,4%	76,5%	0,87 p.p.	Escolhido
Regressão logística (balanceada)	0,7124	0,7069	71,8%	74,7%	1,20 p.p.	Elegível
Análise discriminante (prior. evasão)	0,7013	0,6910	71,2%	74,2%	1,08 p.p.	Elegível

SVM	0,6998	0,6711	72,8%	75,9%	6,92 p.p.	Descartado
SVM (balanceada)	0,6944	0,6981	69,1%	74,0%	8,07 p.p.	Descartado
Análise discriminante linear	0,6861	0,6817	69,1%	75,7%	0,68 p.p.	Elegível
Árvore de decisão	0,6826	0,6634	70,2%	73,7%	6,59 p.p.	Descartado
Árvore de decisão (balanceada)	0,6712	0,6713	67,1%	70,7%	6,22 p.p.	Descartado
Naive Bayes gaussiano	0,6305	0,5705	69,1%	67,2%	0,66 p.p.	Elegível
K vizinhos mais próximos	0,6235	0,5987	64,8%	71,1%	3,43 p.p.	Elegível

As três maiores pontuações (as duas florestas aleatórias e o gradient boosting) foram descartadas pelo critério de estabilidade. Em relação à melhor delas, a regressão logística perde 0,0331 em F1 macro, mas identifica mais evasores (+0,52 p.p. de revocação), que é a métrica prioritária do projeto. O modelo final usa regularização L2 (C = 1) e foi treinado com Python 3.10.11 e scikit-learn 1.6.1.

6. RESULTADOS NO TESTE

As métricas abaixo foram calculadas uma única vez, sobre os 885 estudantes do conjunto de teste.

MÉTRICA	**VALIDAÇÃO CRUZADA**	**TESTE**
Acurácia	76,52%	76,84%
Acurácia balanceada	-	67,54%
F1 macro	0,6774	0,6826
Revocação da evasão	76,35%	76,76%

Os resultados de teste ficaram muito próximos dos da validação cruzada, e a acurácia variou apenas 0,47 p.p. em relação ao conjunto de desenvolvimento. Isso mostra que o modelo generaliza bem para dados que não viu durante o treino.

6.1. EVASÃO

Como a identificação da evasão é o foco do projeto, a Tabela 8 detalha o desempenho nessa classe. A revocação indica quantos dos evasores reais o modelo encontrou; a precisão, quantos dos estudantes apontados como evasores de fato evadiram.

MÉTRICA	VALIDAÇÃO CRUZADA	TESTE
Revocação	76,76%	218 dos 284 identificados
Precisão	79,27%	218 dos 275 apontados como evasão evadiram
F1	0,7800	Média harmônica entre precisão e revocação
Especificidade	90,52%	544 dos 601 não evasores classificados corretamente
Acurácia evade x não evade	86,10%	762 acertos em 885 estudantes

O modelo identifica cerca de 77 em cada 100 estudantes que evadem. Os 66 casos restantes não foram sinalizados, e 37 deles foram classificados como formados. Vale notar que a acurácia geral de 76,84% se refere às três classes em conjunto e não deve ser lida como o desempenho na evasão.

6.2. MATRIZ DE CONFUSÃO E DESEMPENHO POR CLASSE

Real / Prevista	Dropout	Enrolled	Graduate	Total
Dropout	218	29	37	284
Enrolled	43	53	63	159
Graduate	14	19	409	442

Classe	Precisão	Revocação	F1	Estudantes
Dropout	79,3%	76,8%	0,7800	284
Enrolled	52,5%	33,3%	0,4077	159
Graduate	80,4%	92,5%	0,8601	442
Média macro	70,7%	67,5%	0,6826	885

A classe Enrolled tem o pior desempenho: o modelo reconheceu 53 dos 159 casos (33,3%) e confundiu a maior parte dos demais com Graduate. É isso que explica a diferença entre a acurácia (76,8%) e a acurácia balanceada (67,5%).

As probabilidades estimadas pelo modelo são bem calibradas. O erro de calibração esperado (ECE) foi de 0,0159, abaixo da referência de 0,05: quando o modelo atribui 80% de chance a uma classe, a frequência observada fica próxima desse valor. A exceção é a faixa entre 20% e 40% de probabilidade de evasão, em que o risco é superestimado em cerca de 10 pontos.

7. ATRIBUTOS MAIS INFLUENTES

A influência de cada atributo foi medida pela média do valor absoluto dos coeficientes da regressão logística nas três classes.

ATRIBUTOS	GRUPOS	INFLUÊNCIA
UCs 2°Sem. Aprovadas	Desempenho no 2°Semestre	20,1%
UCs 1°Sem. Aprovadas	Desempenho no 1°Semestre	12,7%
UCs 2°Sem. Matriculadas	Desempenho no 2°Semestre	11,9%
Mensalidades em dia	Situação Financeira	6,0%
Média 2°Sem.	Desempenho no 2°Semestre	4,7%

O desempenho acadêmico domina a decisão: os três primeiros atributos somam 44,7% da influência. Entre os fatores não acadêmicos, o mais relevante é a situação das mensalidades.

8. LIMITAÇÕES E PRÓXIMOS PASSOS

Os atributos categóricos, como curso, estado civil e nacionalidade, entram no modelo como códigos numéricos, sem codificação one-hot. Isso impõe uma ordem que não existe entre as categorias e prejudica principalmente modelos lineares. A baixa detecção da classe Enrolled faz com que ela apareça subestimada nos painéis. Além disso, os dados vêm de uma única instituição, e o desempenho pode variar em outro contexto. Por esses motivos, a classificação deve servir de apoio à decisão, e não como decisão automática.

Os próximos passos são concluir a integração do processamento em lote via Kafka, aplicar a codificação one-hot aos atributos categóricos e refazer a comparação dos algoritmos, verificando o ganho na classe Enrolled.