Faculdade de Tecnologia de Franca “Dr. Thomaz Novelino”
Desenvolvimento de Software Multiplataforma · Projeto Interdisciplinar do 6º semestre

Plataforma de Acompanhamento Educacional

PAE

Classificação de estudantes quanto ao risco de evasão, com aplicação Web, aplicativo Mobile e serviços em nuvem

Guilherme Luis e Miguel Angelo Silva
Orientador: Prof. Me. Alexandre Gomes
Franca, 2026

Contexto e justificativa

Contexto

A evasão é um problema recorrente em instituições de ensino e em entidades que acompanham crianças, adolescentes e jovens. Quando um estudante abandona os estudos, perde-se o investimento feito na sua formação e também a chance de oferecer apoio enquanto ainda havia tempo.

O projeto foi ambientado em Franca/SP, inspirado no trabalho do CMDCAF, o conselho municipal que registra e acompanha as entidades de atendimento à criança e ao adolescente. Trata-se de uma ambientação acadêmica, sem parceria oficial com o conselho ou com qualquer órgão público.

Justificativa

As equipes de acompanhamento trabalham com tempo e pessoal limitados e precisam decidir quais estudantes atender primeiro. Essa decisão costuma depender da percepção de cada profissional, e o risco de evasão muitas vezes só fica evidente quando já é tarde para intervir.

As instituições, porém, já possuem dados acadêmicos e socioeconômicos que, analisados de forma sistemática, podem indicar esse risco mais cedo. O PAE foi criado para usar esses dados na priorização dos atendimentos.

Objetivo da plataforma

O PAE permite que a instituição cadastre seus estudantes, solicite uma classificação feita por um modelo de aprendizado de máquina e registre as ações de acompanhamento. O modelo indica se o perfil do estudante se aproxima mais do grupo que evadiu, do grupo que continuou matriculado ou do grupo que concluiu o curso, e a plataforma transforma esse resultado em um nível de prioridade.

1 Cadastro

O estudante é registrado com 36 atributos acadêmicos e socioeconômicos, vinculado à sua instituição.

2 Classificação

O serviço de IA estima a classe mais provável e a confiança associada a ela.

3 Priorização

Uma regra de negócio converte classe e confiança em prioridade alta, média ou baixa.

4 Acompanhamento

A equipe registra as ações tomadas e a situação de cada caso.

A classificação é uma ferramenta de apoio. O score de confiança mostra com que frequência perfis semelhantes tiveram aquele desfecho no conjunto de teste e não substitui a avaliação de quem acompanha o estudante.

Requisitos da plataforma

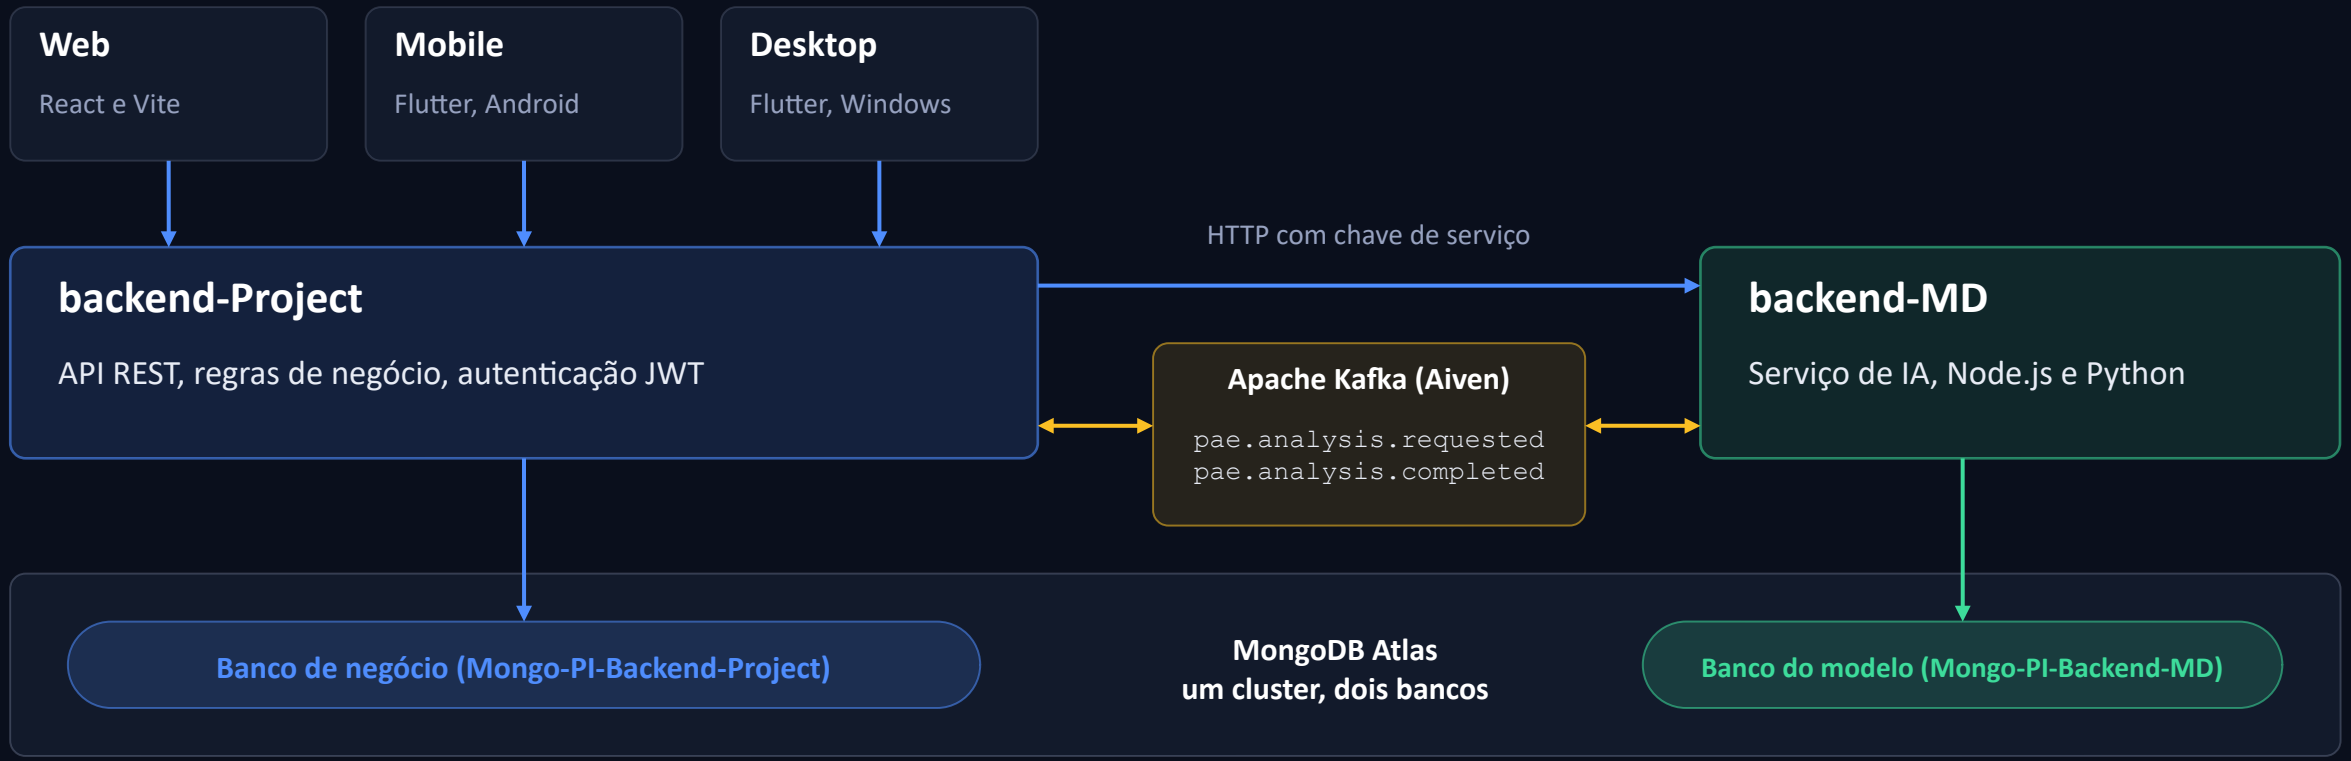
Requisitos funcionais

- Autenticação com três perfis de acesso e troca de senha pelo próprio usuário.
- Cadastro de instituições, usuários e estudantes, com desativação em vez de exclusão.
- Análise individual e em lote, com gravação do histórico de cada estudante.
- Simulação de classificação sem gravar o resultado.
- Registro das ações de acompanhamento e da situação de cada caso.
- Painel com indicadores e tela de mineração de dados com as métricas do modelo.

Requisitos não funcionais

- Acesso por HTTPS, com senhas protegidas por hash e autenticação por token.
- Uma única API para Web, Mobile e Desktop, com as mesmas regras de negócio.
- Interface disponível em português, inglês e espanhol.
- API documentada no padrão OpenAPI.
- Modelo reprodutível, com metadados registrados a cada treino.
- Nenhum dado que identifique o estudante nas mensagens trocadas entre os serviços.

Arquitetura da solução



Web, Mobile e Desktop se comunicam somente com o backend-Project, que concentra a autenticação, as regras de negócio e o acesso ao banco. A classificação fica isolada no backend-MD, chamado por HTTP na análise individual e por meio do Kafka no processamento em lote. Os dois serviços usam o mesmo cluster do MongoDB Atlas, mas cada um tem o seu próprio banco de dados.

Tecnologias utilizadas

Camada	Tecnologias	Papel na solução
Web	React 19, Vite 8 e TypeScript 7	Interface Web com componentes e gráficos próprios, sem bibliotecas de UI.
Mobile e Desktop	Flutter 3.41 e Dart 3.11, com Provider e go_router	Aplicativo com as mesmas telas e rotas da Web, com o token em armazenamento seguro.
API principal	Node.js, Express 5, JWT, bcrypt e Swagger	Autenticação, regras de negócio e documentação OpenAPI.
Serviço de IA	Python, scikit-learn 1.6, pandas e joblib	Preparação dos dados, treino e inferência do modelo.
Banco de dados	MongoDB Atlas com Prisma 6	Um banco para os dados de negócio e outro para os metadados do modelo.
Mensageria	Apache Kafka no Aiven, pela API REST v2	Envio e retorno dos lotes de análise entre os dois serviços.
Nuvem	Microsoft Azure	Hospedagem da aplicação Web e dos serviços, com HTTPS.
Testes	Cypress, flutter test e flutter analyze	Testes de ponta a ponta na Web e testes de unidade no aplicativo.

Perfis de acesso e integridade dos dados

Perfil	Permissões
Administrador	Gerencia usuários e instituições e acessa os dados de todas as instituições.
Analista	Cadastra estudantes, executa análises e conduz os acompanhamentos da sua instituição.
Consulta	Visualiza os dados da própria instituição, sem permissão de alteração.

Usuários que não são administradores enxergam apenas os dados da própria instituição. Essa restrição fica em um único middleware, e o usuário é consultado no banco a cada requisição, de modo que uma conta desativada perde o acesso imediatamente, sem esperar o token expirar.

As análises nunca são sobrescritas. Cada execução gera um novo registro com uma cópia dos atributos usados, o que permite auditar um resultado antigo mesmo depois que o cadastro do estudante foi alterado. O resumo da última análise é gravado no estudante na mesma transação.

Pelo mesmo motivo, usuários, instituições e estudantes são desativados em vez de excluídos, já que o histórico depende deles.

Regra de prioridade de acompanhamento

Classe prevista	Confiança	Prioridade	Leitura para a instituição
Evasão	0,6 ou mais	Alta	Acompanhamento prioritário
Evasão	abaixo de 0,6	Média	Acompanhamento recomendado
Matriculado	qualquer	Média	Observação continuada
Concluinte	abaixo de 0,6	Média	Observação continuada
Concluinte	0,6 ou mais	Baixa	Sem indicativo de prioridade

O backend-MD devolve somente a classe prevista e a confiança. Decidir o que a instituição faz com esse resultado é uma regra de negócio, implementada no backend-Project; a Web e o aplicativo apenas exibem a prioridade calculada.

O limiar de 0,6 foi definido com base na calibração do modelo, medida no conjunto de teste. O erro de calibração esperado (ECE) ficou em 0,016. Entre os casos classificados como prioritários, a confiança média informada foi de 88,6%, e 87,9% desses estudantes de fato evadiram.

Fluxo de uma análise individual

1

Requisição

A Web ou o aplicativo envia o pedido com o token JWT do usuário.

2

Validação

O backend-Project confere o perfil, a instituição e os atributos.

3

Classificação

O backend-MD valida a chave de serviço e executa o modelo em Python.

4

Prioridade

A classe e a confiança são convertidas em prioridade de acompanhamento.

5

Registro

A análise e o resumo do estudante são gravados na mesma transação.

Resposta do backend-MD

```
{
  "classification": "Dropout",
  "confidence": 0.78
}
```

A análise individual é síncrona porque o usuário espera o resultado na tela. O módulo mdClient é o único ponto do backend-Project que chama o serviço de IA, e é ele que traduz as falhas para o cliente.

Um atributo inválido continua sendo erro 422, mas uma chave de serviço recusada vira erro 502, para que o aplicativo não confunda um problema de configuração do servidor com uma sessão expirada.

Processamento em lote com mensageria

1. **Pedido do lote**

   O cliente envia até 200 estudantes. O backend-Project cria um job com situação QUEUED e responde 202.

2. **Publicação**

   O pedido vai para o tópico pae.analysis.requested apenas com os atributos, sem dados que identifiquem o estudante.

3. **Classificação**

   O backend-MD consome a mensagem, classifica o lote e publica o resultado em pae.analysis.completed.

4. **Gravação**

   O backend-Project grava as análises e encerra o job como DONE ou FAILED.

5. **Acompanhamento**

   A Web e o aplicativo consultam a situação do job por até cinco minutos.

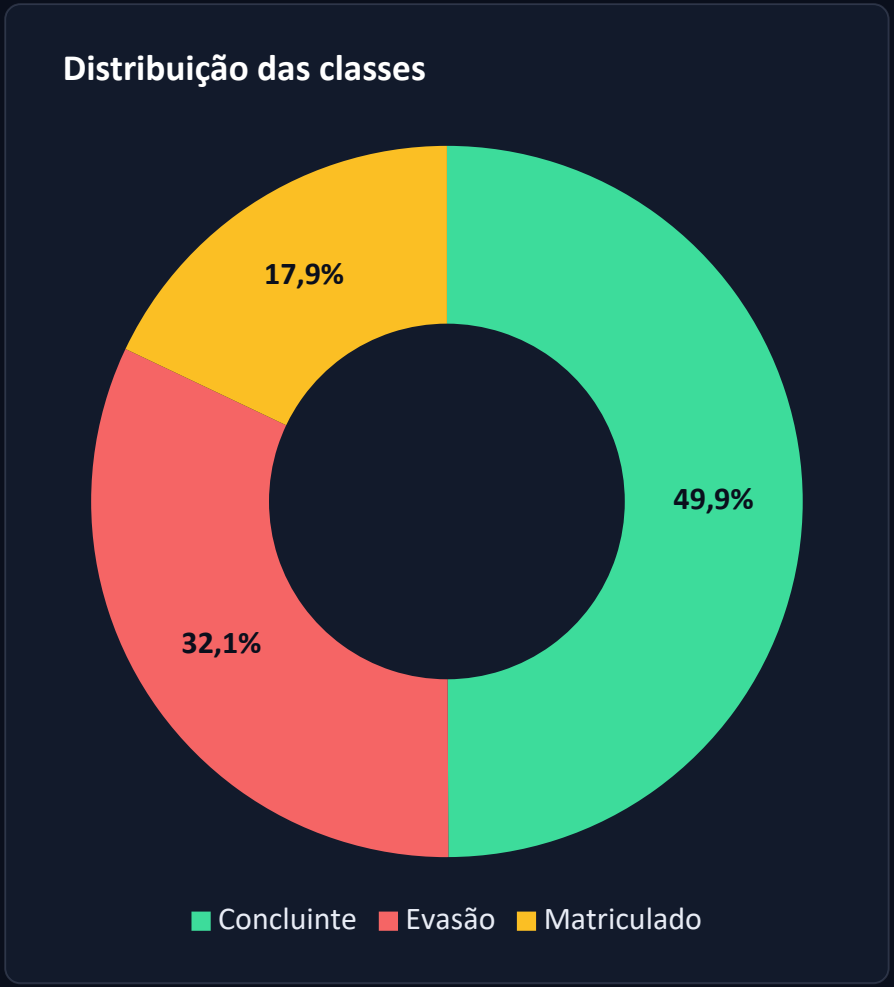
Confiabilidade

A comunicação usa o Apache Kafka gerenciado pelo Aiven, acessado pela API REST com HTTPS e autenticação básica. O consumidor é idempotente: se uma mensagem for entregue mais de uma vez, a análise não é duplicada.

Um erro nos dados encerra o job como FAILED, e uma falha ao publicar devolve 503 sem deixar nenhum job esperando por uma mensagem que não existe. Como os tópicos guardam as mensagens por 72 horas, um pedido feito com o backend-MD fora do ar é processado quando o serviço volta.

Com a variável KAFKA_ENABLED desligada, o lote volta a ser processado de forma síncrona.

Base de dados e preparação



A base Predict Students' Dropout and Academic Success, do repositório UCI, reúne 4.424 estudantes e 36 atributos acadêmicos, demográficos e socioeconômicos. Não há valores ausentes nem registros duplicados, mas as classes são desbalanceadas: para cada estudante matriculado, há 2,78 concluintes.

O pipeline foi dividido em quatro etapas independentes: definição do ambiente, preparação dos dados, treinamento e inferência. Na preparação, os nomes das colunas são normalizados e a classe-alvo recebe um código fixo. A normalização dos atributos é ajustada somente no conjunto de treino e reaproveitada na inferência, para que nenhum dado de teste influencie o modelo.

Modelo de classificação

Característica	Configuração
Algoritmo	Regressão logística multinomial (scikit-learn)
Regularização	L2, com C = 1,0
Otimizador	lbfgs, com até 1.000 iterações
Pré-processamento	Atributos padronizados com StandardScaler
Divisão dos dados	80% para desenvolvimento e 20% para teste, de forma estratificada
Validação	Cruzada estratificada, com 10 partições
Saída	Classe prevista e probabilidade de cada uma das três classes

Por que a regressão logística

A regressão logística atende bem ao propósito da plataforma. Como é treinada minimizando a perda logarítmica, ela produz probabilidades bem calibradas, e é isso que sustenta o limiar de 0,6 usado na regra de prioridade.

O modelo também é estável: a diferença entre o desempenho no treino e na validação ficou em 0,009. Além disso, os coeficientes permitem ver quais atributos mais pesam na classificação, como será mostrado adiante.

O algoritmo foi definido a partir de uma comparação entre 13 candidatos por validação cruzada, com um critério que dá o mesmo peso ao F1 macro e à revocação da classe Evasão.

Resultados no conjunto de teste

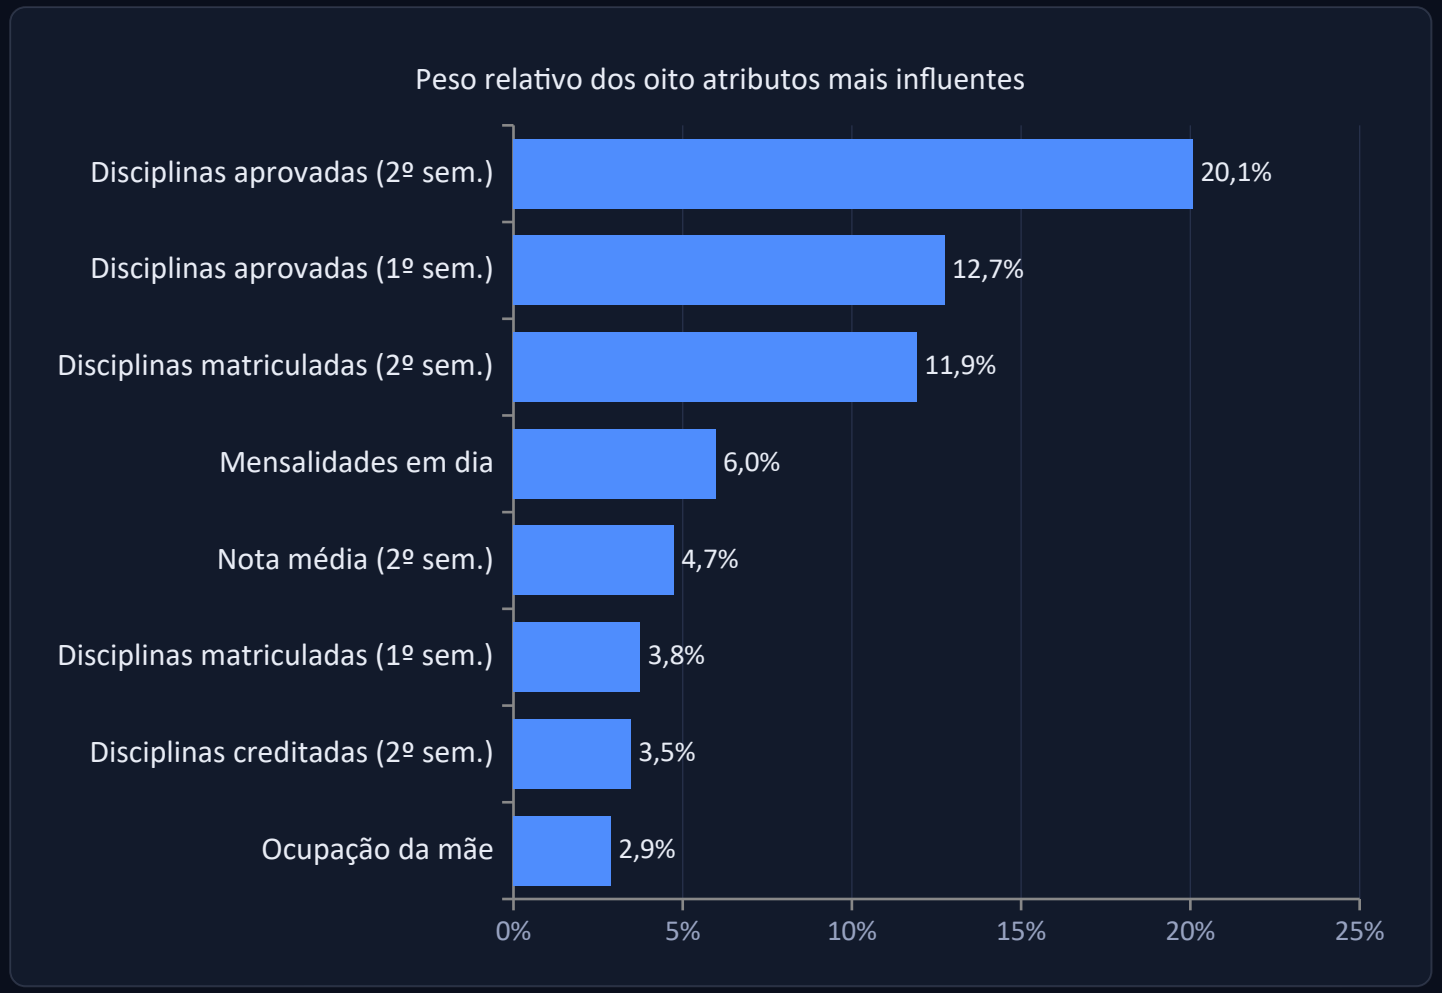
Métrica	Valor
Acurácia	76,8%
Acurácia balanceada	67,5%
F1 macro	0,683
Revocação da classe Evasão	76,8%
Erro de calibração (ECE)	0,016

Matriz de confusão (linhas indicam a classe real)

	Evasão	Matriculado	Concluinte
Evasão	**218**	29	37
Matriculado	43	**53**	63
Concluinte	14	19	**409**

As métricas foram calculadas uma única vez, sobre 885 registros que não participaram do treinamento. A acurácia balanceada aparece ao lado da acurácia porque, com classes desbalanceadas, ela mostra melhor o desempenho nas classes menores. O modelo identifica 76,8% dos estudantes que evadiram e 92,5% dos que concluíram o curso, mas apenas 33,3% dos que continuavam matriculados.

Atributos mais influentes



Os atributos ligados ao desempenho no primeiro ano concentram quase metade do peso do modelo: o número de disciplinas aprovadas e matriculadas nos dois semestres soma cerca de 48%. A situação das mensalidades aparece logo em seguida, como quarto atributo mais influente.

O peso é a média do valor absoluto dos coeficientes da regressão logística entre as três classes, calculada sobre atributos padronizados. Em colunas nominais, como curso e ocupação dos pais, esse valor deve ser lido com cautela, porque esses códigos entram no modelo como números.

Limitações conhecidas

Classe Matriculado

É a classe mais difícil de identificar: o modelo reconhece 53 dos 159 casos do teste. Ela é a menor das três e também a mais ambígua, já que o estudante ainda pode evadir ou concluir o curso.

Variáveis nominais

Atributos como curso, estado civil e ocupação dos pais são códigos e entram no modelo como números contínuos, sem codificação one-hot. Com isso, o modelo trata o curso 171 como se fosse “maior” que o curso 33, uma relação que não existe.

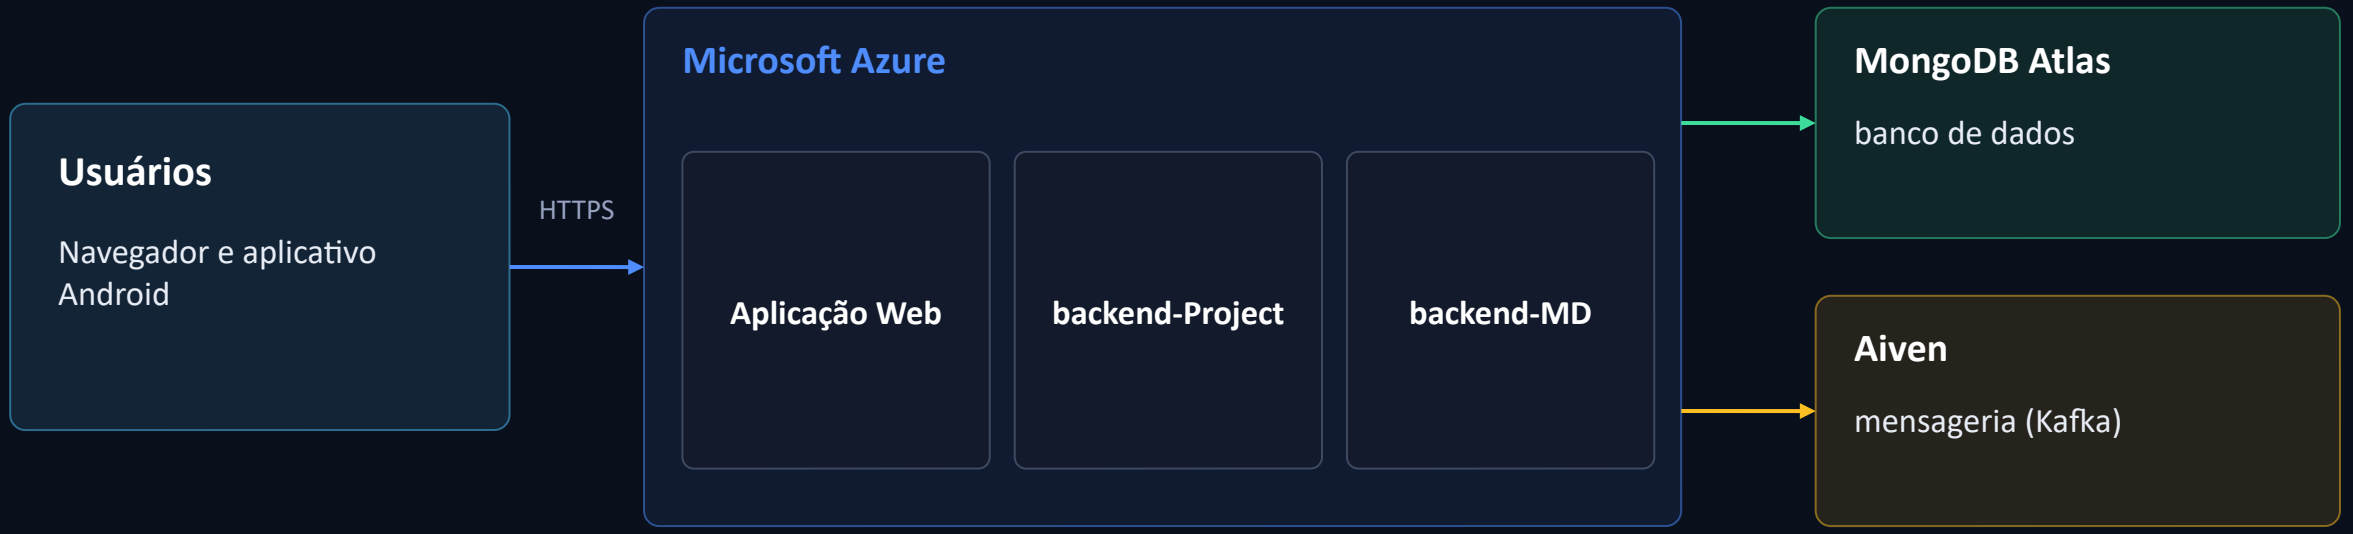
Calibração

A calibração foi medida nesta base e pode mudar em outra instituição ou em outro período. Na faixa de 0,2 a 0,4 de probabilidade de evasão, o modelo superestima o risco em cerca de 0,10.

Reflexo no painel

Como a classe Matriculado é pouco reconhecida, a distribuição por classificação no painel subnotifica essa classe. Por isso, a tela de mineração de dados mostra a acurácia balanceada, a matriz de confusão e o relatório por classe.

Publicação na nuvem



A solução está publicada na Microsoft Azure e é acessada por HTTPS, tanto pelo navegador quanto pelo aplicativo. O banco de dados e a mensageria ficam em serviços gerenciados, o MongoDB Atlas e o Aiven, que mantêm réplicas dos dados sem exigir operação da equipe.

Os serviços reiniciam automaticamente em caso de falha, e a publicação usa a mesma base de código do ambiente local, mudando apenas as configurações.

Segurança

Cada credencial do sistema identifica uma coisa diferente: o token JWT identifica a pessoa, e a chave de serviço identifica o backend-Project perante o serviço de IA. Por isso, o token do usuário nunca é repassado ao backend-MD.

Camada	Como é protegida
Usuários	Senhas armazenadas com bcrypt e autenticação por JWT. Perfil e instituição são verificados a cada requisição, com resposta 401 para token inválido e 403 para permissão insuficiente.
Serviços	O backend-MD exige a chave X-API-Key, comparada em tempo constante. Se a chave não estiver configurada, o serviço recusa todas as requisições.
Transporte	HTTPS em todo o acesso à plataforma, e acesso ao Kafka somente por HTTPS com autenticação básica.
Dados	Nenhum cliente acessa o banco diretamente, o backend-MD não aceita requisições de navegadores e as mensagens não carregam dados que identifiquem o estudante. Os segredos ficam apenas nos arquivos .env do servidor.

Interfaces Web e Mobile

Funcionalidades

A aplicação Web e o aplicativo oferecem as mesmas áreas: painel, estudantes, análise e simulação, histórico, mineração de dados, acompanhamentos e administração de usuários e instituições.

As duas plataformas usam as mesmas rotas, as mesmas cores e os mesmos textos, disponíveis em português, inglês e espanhol. No celular, as tabelas viram cartões, os filtros ficam recolhidos e os formulários abrem em folhas inferiores.

Apresentação do resultado

A confiança é exibida como score com barra, e não como probabilidade de evasão. A cor acompanha a classe prevista, de modo que uma confiança alta em Evasão aparece como sinal de risco. As probabilidades das três classes ficam visíveis, para que um resultado de 54% não pareça igual a um de 99%.

Todo resultado vem acompanhado de um aviso de que se trata de apoio à decisão. O formulário de atributos é gerado a partir do contrato do modelo e destaca valores fora da faixa observada no treino.

Testes, documentação e reprodutibilidade

Testes

A aplicação Web tem sete suítes de testes de ponta a ponta com Cypress, que cobrem login, painel, estudantes, análise, acompanhamentos, usuários e instituições. Esses testes rodam contra os serviços reais, com dados de demonstração, e não contra simulações.

O aplicativo tem 27 testes de unidade, que verificam a leitura dos contratos da API, as regras do formulário e as traduções, e passa no flutter analyze sem apontamentos.

Documentação e reprodutibilidade

Os dois back-ends têm documentação Swagger (OpenAPI) em /api/docs, e cada módulo tem seu próprio README.

A instalação de cada serviço sincroniza o banco, prepara o ambiente Python e treina o modelo sem intervenção manual. Cada treino gera um arquivo de metadados com hiperparâmetros, métricas e versão dos dados, que é registrado no banco do serviço de IA.

Considerações finais

Ao longo do semestre, o classificador construído no 5º semestre evoluiu para uma plataforma multiplataforma, que integra aplicação Web, aplicativo Mobile, dois serviços de back-end, mensageria e nuvem pública, conforme pede o Manual do PI.

Hoje a plataforma está publicada na Azure, e o modelo de classificação em uso foi escolhido por critérios documentados e avaliado em dados que não participaram do treinamento.

Também procuramos deixar claros os limites do modelo, tanto na documentação quanto na própria interface, porque a ferramenta só é útil se quem a utiliza entende o que o resultado significa.

PAE

Obrigado pela atenção

Ficamos à disposição para perguntas.

Plataforma publicada

pae-pi6.canadacentral.cloudapp.azure.com

Repositório

github.com/FatecFranca/DSM-G10-PI6-2026-2

Aplicativo Android

Leia o QR code para baixar o APK.

Guilherme Luis e Miguel Angelo Silva · Orientador: Prof. Me. Alexandre Gomes